

深度学习在光纤成像中的应用进展(特邀)

孙佳伟¹, 陈照青¹, 赵斌^{1,2*}, 李学龙^{1,3}¹上海人工智能实验室智能光电中心, 上海 200232;²西北工业大学光电与智能研究院, 陕西 西安 710072;³中国电信人工智能研究院, 北京 100033

摘要 光纤成像技术借助光纤的微小尺寸与柔韧性能实现对狭窄区域的高分辨率成像,在生物医学、工业检测等领域都有广泛应用。然而,在基于多芯或多模光纤的成像系统中,存在着诸多瓶颈问题限制其成像分辨率与精度。简要介绍了荧光成像、定量相位成像、散斑成像、光谱成像等多种光纤成像模态中应用深度学习解决瓶颈问题的代表性研究工作,并讨论了深度学习与光纤成像交叉研究领域的现有瓶颈,展望了智能光纤成像系统的应用前景。

关键词 光纤成像; 深度学习; 多芯光纤; 多模光纤; 内窥成像

中图分类号 O439

文献标志码 A

DOI: 10.3788/LOP241401

Advances in Deep Learning Based Fiber Optic Imaging (Invited)

Sun Jiawei¹, Chen Zhaoqing¹, Zhao Bin^{1,2*}, Li Xuelong^{1,3}¹Intelligent Photonics and Electronics Center (IPEC), Shanghai Artificial Intelligence Laboratory, Shanghai 200232, China;²School of Artificial Intelligence, Optics and ElectroNics (iOPEN), Northwestern Polytechnical University, Xi'an 710072, Shaanxi, China;³Institute of Artificial Intelligence (TeleAI), China Telecom Co. Ltd., Beijing 100033, China

Abstract Fiber optic imaging technology can achieve high-resolution imaging in narrow areas due to the small size and flexibility of optical fibers. Fiber optic imaging can also be employed in biomedical research and industrial inspections. However, there are bottleneck problems in multi-core and multi-mode fiber imaging systems, limiting their resolution and accuracy. This paper briefly introduces representative research on the applications of deep learning to address these bottleneck problems in various fiber imaging modalities such as fluorescence imaging, quantitative phase imaging, speckle imaging, and multispectral imaging. Existing bottleneck in this interdisciplinary research field involving deep learning and fiber optic imaging are also discussed. Additionally, we envision the broad application prospects of intelligent fiber optic imaging systems.

Key words fiber optic imaging; deep learning; multi-core fiber; multi-mode fiber; endoscopy

1 引言

光纤成像技术是一种利用光纤作为传输介质,借助光纤的微小尺寸和优异的柔韧性实现对狭窄区域高分辨率成像的技术。在光纤成像过程中,携带图像信息的入射光在缩束后进入光纤,经过光纤传输并在输出端成像。该技术由于在成像过程中对样本无损坏且在传输过程中信息保真度较高,在医学临床场景、芯片制造、航天发动机检修等无损检测场景中具有重要应

用价值^[1-7]。

光纤最早应用于通信领域,主要利用光的全内反射原理来实现长距离、低损耗的信息传输。1966年,英国标准电信实验室的高锟等^[8]首次提出使用光纤作为通信媒介传输数据和通信信号,并对光纤材料进行了深入研究。因为在光纤通信技术方面的开创性工作,他在2009年获得诺贝尔物理学奖。同时,研究者发现,通过捆绑大量细小光纤可以实现图像在光纤中的传输,这成为了光纤成像的起源。光纤成像技术的

收稿日期: 2024-06-01; 修回日期: 2024-06-18; 录用日期: 2024-06-27; 网络首发日期: 2024-07-05

基金项目: 国家重点研发计划(2022ZD0160102)、国家自然科学基金(62376222)、中国科协青年人才托举工程(2023QNRC001)

通信作者: *binzhao111@gmail.com

出现推动了光纤内窥镜技术的发展,该技术在临床诊断尤其是胃肠道检查中发挥了重要作用^[9]。然而,光纤束中上万根纤芯的离散随机分布导致成像分辨率和对比度下降。此外,光纤在弯曲时存在光信号丢失等问题限制了光纤成像的进一步应用^[10]。为了解决这些问题,计算成像技术通常被用于校准和增强光纤的输出图像,从而提高光纤成像的质量。计算成像还能够在不损害样本的前提下,进一步恢复输入光场的相位信息和三维空间信息等特征信息,这对临床医学诊断和精密工业检测具有重大意义^[2-4,11-13]。

传统的光纤成像方式主要分为波前整形、目标重建和光场调控三类方法。波前整形通过空间光调制器对光纤施加多维度的波前调控,以解决图像在传输过程中失真的问题。这类方法包括迭代式波前优化^[14-22]、基于光学记忆效应的波前共轭^[23-26]以及构建光纤传输矩阵^[27-40]等。然而,这些方法往往需要复杂的波前调控设备,对光学硬件的要求较高且操作繁琐。为了减少额外的设备和操作需求,研究人员提出了目标重建方法,旨在从光纤输出端的失真光场中恢复图像信息。其主要方法包括基于光纤传输矩阵的重建^[41-43]、利用多次成像时的散斑关联进行重建^[44-50]以及对样本不同位置多次采用单像素探测的压缩感知方法^[51-54]等。除此之外,借助相干光成像的光场调控^[55-57]也是一种有效的光纤成像方式。这类方法通过对复杂介质中输入和输出光场的关系进行光学建模,实现对入射相干光的时空分析。这些研究极大促进了光纤成像质量的提高,并扩展了光纤成像技术的应用范围。然而,光纤成像技术仍然面临成像质量低和速度慢等瓶颈问题。

近年来,蓬勃发展的深度学习在图像处理领域展现出卓越的性能,为光纤成像技术的发展注入了新的动力。深度学习通过数据驱动的方式,从大量数据中学习输入与输出之间的转换关系,从而实现高效且高

质量的图像处理。在光纤成像领域,深度学习已被验证能够以端到端的方式实现光纤散斑的重建,并在相关的下游任务中取得了优异的表现^[58-61]。一些研究者还利用深度学习来获取光纤成像系统的传输矩阵,从而增强成像过程的泛化性^[62-63]。目前,深度学习已成为光纤成像领域重要的计算成像方法之一,并不断推动着该领域的发展。深度学习的引入突破了许多传统方法的局限性,进一步提高了光纤成像的质量和效率。

本文主要探讨了深度学习在光纤成像领域的应用,并分析了其面临的问题并对未来进行了展望。首先,介绍了光纤成像和深度学习的基本理论,包括常用的光纤类型和光纤成像中常用的深度学习模型。其次,按照光纤类型将光纤成像分为多芯光纤(MCF)成像和多模光纤(MMF)成像。在机器学习驱动的多芯光纤成像中,根据入射光的类型,进一步划分为了非相干光成像和相干光成像。然后,还介绍了一类特殊的多芯光纤成像方法,即基于深度学习的无序安德森定位光纤成像。在多模光纤成像中,本文根据成像类型分别讨论了智能散斑成像和智能光谱成像,并进一步探讨了深度学习驱动的多模光纤成像应用。最后,讨论了深度学习驱动的光纤智能成像的最新进展与应用场景,分析了当前光纤成像技术仍存在的问题和挑战,并对光纤智能成像的未来进行了展望,提出了光纤成像技术潜在的发展方向 and 现有瓶颈可能的解决方案。

2 基本原理

2.1 光纤成像基本原理

光纤是一种常见的光波导元件,根据折射率分布的不同可分为阶跃式光纤和渐变式光纤,其中前者常被用于成像任务。阶跃式光纤一般由纤芯和包层两部分组成,通过全内反射实现成像。为了确保光场图像信息的有效传输,需保证光纤的纤芯折射率 n_{core} 显著高于包层折射率 n_{clad} 。根据折射定律,在满足全内反

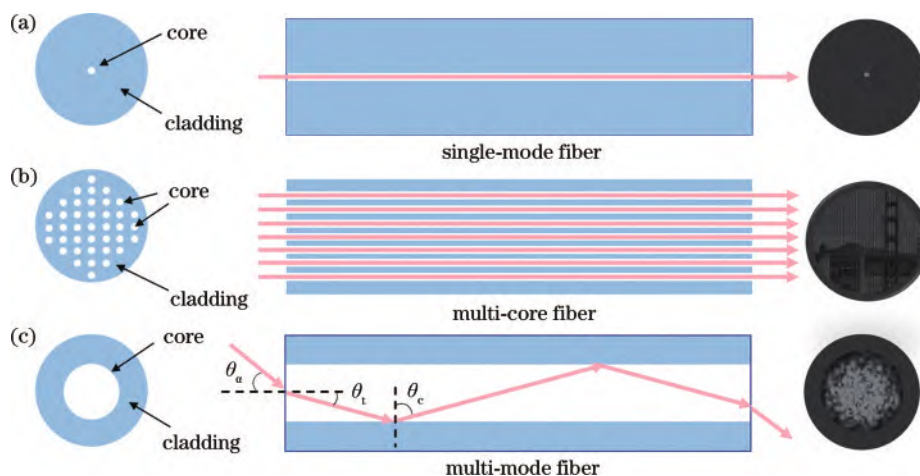


图1 常用光纤的结构、原理和成像示意图。(a)单模光纤;(b)多芯光纤;(c)多模光纤

Fig. 1 Diagram of structures, principle, and imaging result of common optical fibers. (a) Single-mode fiber; (b) multi-core fiber; (c) multi-mode fiber

射时,入射光的反射角必须小于临界角 θ_c ,该临界角 θ_c 为

$$\theta_c = \arcsin \frac{n_{\text{clad}}}{n_{\text{core}}} \quad (1)$$

在光纤的输入端,光的入射角必须控制小于临界角 θ_a ,以满足式(1)中的反射角限制。其中临界角 θ_a 满足

$$\sin \theta_a = \frac{n_{\text{core}} \sin \theta_t}{n} = n_{\text{core}} \sqrt{1 - \cos^2 \theta_t} = \sqrt{n_{\text{core}}^2 - n_{\text{clad}}^2}, \quad (2)$$

式中: n 为光纤所在介质的折射率; θ_t 为入射光以临界角 θ_a 入射时的折射角。利用式(2)还可以计算光纤的数值孔径(NA),以评估光纤能够接收的光入射角范围,进而评估光纤的传输效率和信号质量。在阶跃式光纤中,数值孔径可表示为

$$NA = n \sin \theta_a = \sqrt{n_{\text{core}}^2 - n_{\text{clad}}^2} \quad (3)$$

根据纤芯尺寸的不同,阶跃式光纤可进一步划分为单模光纤(SMF)、多芯光纤和多模光纤。单模光纤的结构与图像传输过程如图 1(a)所示,其纤芯尺寸最小,通常只有 $8 \sim 10 \mu\text{m}$ 。由于其低色散和长距离传输时低信号衰减等特性,单模光纤成为目前通信和激光传导领域的首选光纤类型。然而,由于单模光纤只能传输光的基本模式,很难应用于高分辨率成像,因此光纤成像系统往往使用多芯光纤和多模光纤。

多芯光纤(或称相干光纤束)是由上千根单模光纤纤芯组成的光纤束,尺寸通常为 $200 \sim 800 \mu\text{m}$,其结构和成像过程如图 1(b)所示。在多芯光纤中,每个单独的纤芯都可以作为一个像素孔,将对应位置的光场图

像信息从一端传递到另一端。由于每个纤芯独立传输信号,多芯光纤对光纤弯曲和外界环境因素的敏感度较低,且成像质量较高,目前在光纤内窥镜等多个领域中已有广泛应用。

多模光纤通过容纳多种光的模式实现成像,尺寸通常为 $50 \sim 400 \mu\text{m}$,其结构和成像过程如图 1(c)所示。在多模光纤中,不同模式的光在传播过程中具有不同的传播速度和路径。这导致在成像时它们存在相位差异,因此在光纤的输出端会相互干涉,从而形成强度不均匀的散斑。多模光纤支持的光模式数量可通过光纤归一化频率(通常称为 V 值)进行估算,具体计算方式为

$$V = \frac{\pi}{\lambda} D_{\text{core}} NA, \quad (4)$$

式中: D_{core} 为多模光纤的纤芯直径。

与多芯光纤相比,多模光纤的成本更低且尺寸更小,这使得其成为新型光纤成像系统的研究热点。

2.2 深度学习基本原理

深度学习属于人工智能的重要子领域,通过算法使模型从大量数据中自动学习和改进,从而具备预测输出的能力。近年来,随着数据量的显著增加和算法算力的不断提升,深度学习模型的性能大幅增强,并在多个领域中得到广泛应用。在光纤成像领域,常用的深度学习模型包括全连接网络^[64]、U-Net 模型^[65]和生成对抗网络^[66](GAN)。

全连接神经网络^[67-69]是最基础的深度学习网络架构之一,其结构如图 2(a)所示。该网络的每个神经元都与前一层的所有神经元相连接,从而实现信息在层

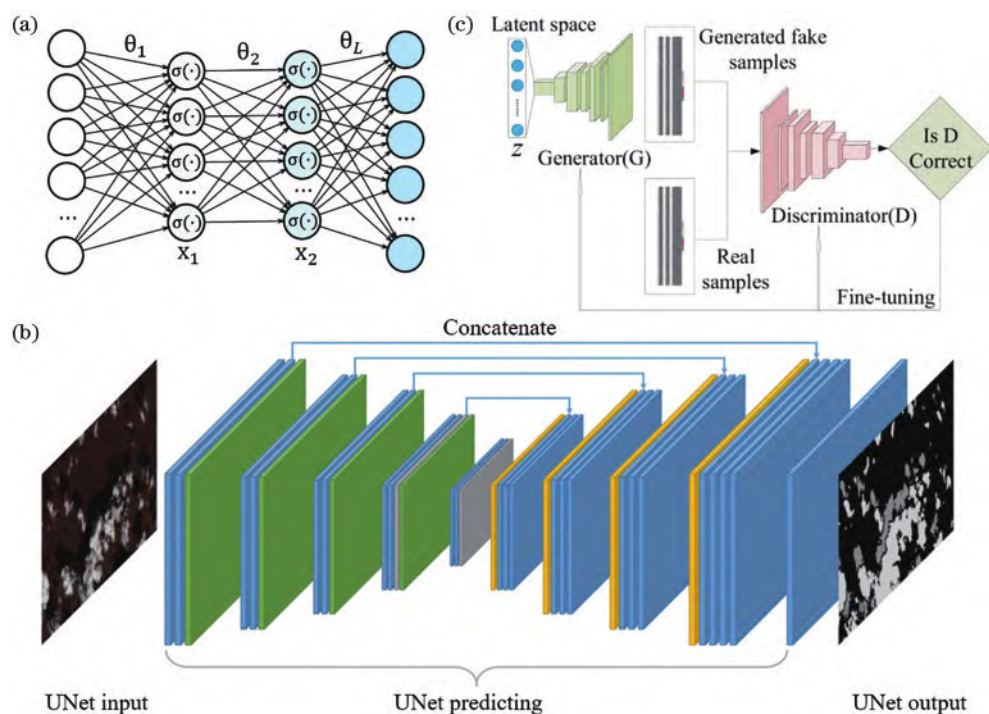


图 2 智能光纤成像中的典型深度学习模型。(a)全连接神经网络^[64];(b)U-Net^[65];(c)GAN^[66]

Fig. 2 Typical deep learning models in intelligent fiber optic imaging. (a) Fully connected neural network^[64]; (b) U-Net^[65]; (c) GAN^[66]

与层之间自由流动。在图像识别、文字处理等领域,全连接神经网络表现出色。然而,随着网络规模的扩大和输入数据维度的提高,全连接神经网络的参数量会急剧增加,进而提高计算成本和模型过拟合风险,因此很难应用于复杂任务。

2015 年,德国弗莱堡大学的 Ronneberger 等^[70]提出的 U-Net 模型是最常用的图像处理模型之一,其结构如图 2(b)所示。U-Net 模型采用了经典的编码器-解码器架构,可以逐步提取图像的高维特征并在随后重建细节信息。此外,U-Net 模型中通常加入跳跃连接以实现不同层之间的信息传递。U-Net 模型的编码器-解码器结构和跳跃连接使得生成的图像能够有效融合高维语义特征和低维细节信息,因此该模型被广泛应用于图像处理任务并均有不俗表现。2014 年,GAN 由 Goodfellow 等^[71]提出,其核心设计思想是生成器和判别器之间的相互“博弈”,其结构如图 2(c)所示。在该框架中,生成器的目标是产生足以混淆判别器的图像,使其难以区分生成图像与真实图像;而判别器的目标则是准确辨别出哪些图像是由生成器产生的。在模型训练过程中,生成器在与判别器的动态对抗过程中自身性能不断提高,进而提高生成图像的质量。

3 深度学习驱动的多芯光纤成像

随着人工智能技术的不断发展,深度学习模型已在图片识别、图片分类、图像复原、医学影像分析等领域达到甚至超越了人类水平。在光纤成像领域,传统成像方法通常依赖于透镜、材料、传感器等硬件升级或光学物理模型优化来提升时空分辨率,然而受物理极限的限制,进一步提升成像系统性能的幅度较为困难且成本较高。近期的一些研究运用深度学习模型强大的图像处理能力提升光纤成像的时空分辨率,在减少系统成本的同时加快了技术迭代速度,同时多模态学习方法还能集成多种数据源以提升系统的整体性能,本文将这些借助深度学习辅助光纤成像的方法统称为智能成像。在光纤成像领域,基于深度学习的智能成像方法常通过神经网络来学习光纤输入端与输出端图像之间的映射关系,采用大量的训练数据或与物理模型相结合的方式进一步提升光纤成像系统的性能。

3.1 基于多芯光纤的智能非相干成像

多芯光纤通常由成千上万个纤芯组成,这些纤芯排列呈蜂窝状,共享同一个包层。在多芯光纤非相干成像系统中,每个纤芯可作为独立的成像像素将强度信息从光纤远端传输至光纤近端,并通过目镜或图像采集系统成像。目前,基于多芯光纤的内窥镜已广泛应用于工业检测、生物医学成像等领域^[72]。然而,在实际应用中,多芯光纤纤芯的蜂窝状结构会导致图像中存在伪影,并限制系统的空间分辨率,尤其在生物医学

临床应用中,该蜂窝状伪影会大幅降低病理组织成像的对比度与分辨率,进而影响临床内窥诊断的准确性。因此,在多芯光纤非相干成像领域,解决蜂窝状伪影问题有助于提高光纤成像系统的分辨率,促进光纤内窥成像技术的发展。

傅里叶域滤波^[73]与图像插值^[74]是常见的去像素化方法,傅里叶域滤波通过对图像进行傅里叶变换后在频域内滤波去除周期性的结构伪影;图像插值通过计算像素周围的像素值来估算新像素点的值,从而平滑图像并减少像素化现象,这些传统方法可以一定程度上消除结构化的蜂窝伪影,但效果欠佳且需要针对性地调整算法参数。最大后验估计^[74]和压缩感知^[75]等图像优化算法可以通过引入先验信息来提高成像质量,但这些方法依赖于迭代架构,所需计算时间较长,难以满足实时图像处理的实际应用需求。多帧融合超分辨率方法^[76]通过移动或旋转光纤捕获一系列时序图像以增加空间信息,通过图像融合来提高成像系统的空间分辨率并消除结构性伪影,然而需要通过复杂的图像配准技术进行精确对齐,最终图像质量受对齐误差的影响较大。

最近,深度学习在图像超分辨率等任务中显示出强大的非线性拟合能力^[77]。2011 年,瑞士日内瓦大学的 Ravi 等^[78]报道了将神经网络方法应用于多芯光纤非相干成像的首次尝试。他们首先使用插值方法去除了蜂窝状图案,应用神经网络学习插值法恢复后的图像与高分辨率真值图像之间的映射关系,以进一步提高分辨率。然而,该模型仅在合成数据集中验证了其性能,距离实际应用仍有距离。为了解决多芯光纤成像实验数据集稀缺和图像对齐困难等问题,图 3 展示了一个基于同轴双传感器的光纤成像系统^[79],该系统能够获得高分辨率真值图像与光纤图像一一对应的配对数据集,并通过生成对抗复原神经网络^[80]、基于物理模型的神经网络^[79]、多帧图像融合^[81]等方法学习光纤图像与对应高分辨率真值图像之间的映射关系,在分辨率测试板和人体组织学样本上进行的实验结果证明这些方法能有效去除蜂窝状伪影并提高空间分辨率。2023 年,南京理工大学左超课题组^[79]将基于物理模型的深度神经网络应用于红外波段的多芯光纤成像技术,拓展了基于多芯光纤的智能非相干成像技术在热辐射检测领域的工程应用范围。深度学习能够在训练数据中自适应学习和提取有效图像特征,该特性使其计算效率往往优于传统图像处理算法,另外,深度学习模型通过多层非线性变换,能够构建复杂的数据映射关系,有效补全了光纤纤芯间的区域,从而改善成像质量。

为了进一步减少光纤成像的侵入性,无透镜光纤内窥镜摒弃了传统的透镜系统,改良后的内窥镜具有体积小、灵活性高等优点,非常适合微创成像或进入难以到达的部位进行诊断^[72]。然而,在使用无透镜光

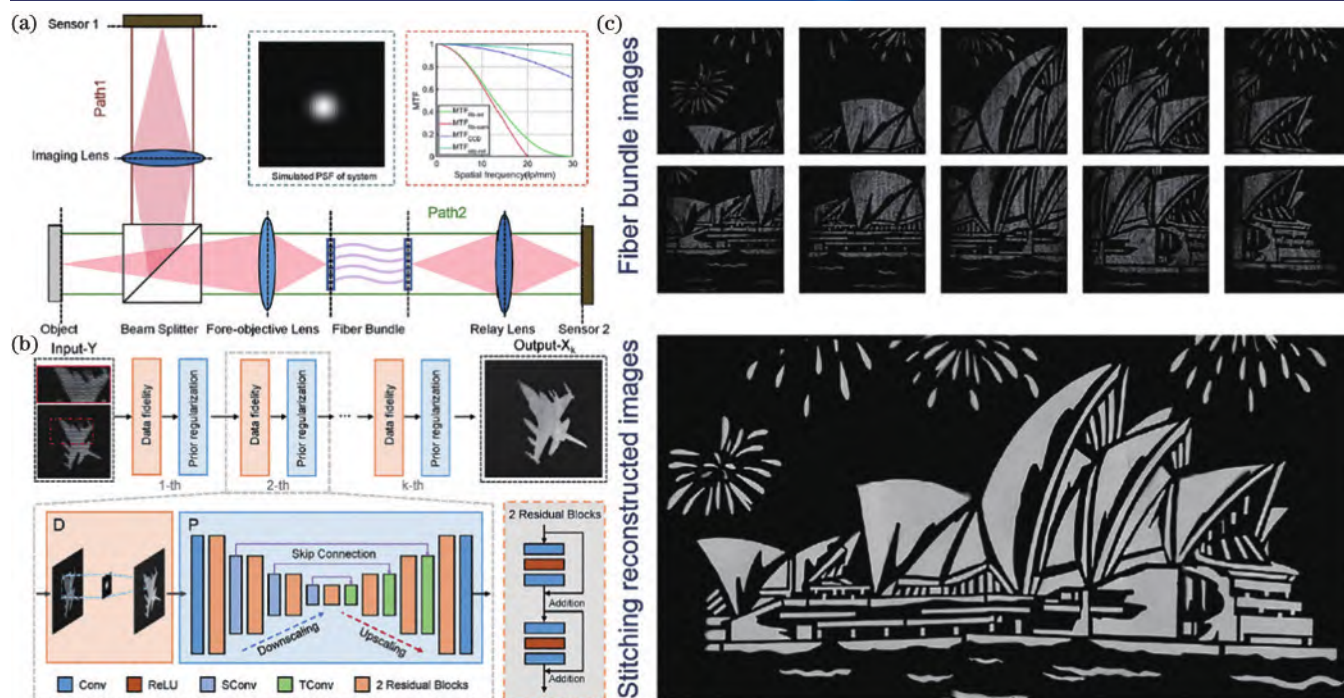


图3 基于多芯光纤的非相干成像^[79]。(a)同轴双传感器光纤成像系统;(b)基于MBIN(model-based iterative network)的图像修复模型整体结构;(c)基于多芯光纤的非相干成像图以及拼接后的深度学习重建图像

Fig. 3 Incoherent imaging based on multi-core optical fiber^[79]. (a) In-line dual-sensor fiber imaging system; (b) overall structure of the image restoration model based on MBIN (model-based iterative network); (c) incoherent imaging results based on multi-core optical fiber and reconstruction images by deep learning after splicing

纤内窥镜进行非相干成像时,除去多芯光纤自身结构带来的蜂窝状伪影^[82],还存在散射和衍射导致的图像模糊问题。2022年,德国德累斯顿工业大学 Czarske 课题组^[83]基于端到端神经网络对单张无透镜光纤图像进行高分辨率显微成像,并利用数字孪生技术扩充训练数据集^[10],在胶质母细胞瘤的识别实验中分类准确率从 90.8% 提高至 95.6%。该团队进一步将深度学习用在基于衍射光学元件的无透镜光纤内窥镜中,采用 U-Net^[11]模型与单层感知器^[84]等深度学习方法,实现了视频帧率级的单曝光 3D 成像。这些技术进一步提升了无透镜光纤内窥镜荧光、白光等非相干光成像的性能,并探索了其在神经外科等临床应用中的可能性。

3.2 基于多芯光纤的智能相位成像

定量相位成像是一种无标记显微成像技术^[85],通过测量光波穿过样本时的相位变化来提供样本的物理、生化属性等重要信息,如细胞质量、体积、表面积等。然而,由于光场在多芯光纤上万根纤芯中传播的光程各不相同,使用多芯光纤进行定量相位成像存在相位失真等瓶颈问题。2022年,德国德累斯顿工业大学 Sun 等^[3]提出了远场单振幅散斑传递方法,仅通过光纤测量端的散斑图像就可以恢复样品的准确相位信息,率先在无透镜多芯光纤内窥镜中实现了定量相位成像。然而,远场单振幅散斑传递方法需要拍摄无样品时的散斑图像以进行系统校准,且所基于的迭代架构[图 4(b)]导致计算速度迟缓。

因此,2024年,德国德累斯顿工业大学的 Sun 等^[4]提出基于深度神经网络的免校准单振幅远场散斑传递方法,利用端到端深度神经网络[图 4(c)]学习光纤近端远场散斑图像与远端相位图像之间的映射关系,并针对光纤定量相位成像高质量数据稀缺的问题,搭建了基于光场调控的远场散斑数据采集平台,如图 4(a)所示,还构建了 50000 对针对多芯光纤定量相位重建问题的“散斑-相位”开源数据集,利用端到端深度神经网络大幅提升相位重建速度,实现了 181 frame/s 的高保真光纤定量相位成像,拓展了深度学习在光纤定量相位成像领域中的应用并提供了基础数据。

3.3 基于无序光纤的智能成像

无序安德森定位光纤^[86](Anderson localizing disordered fiber)是一种特殊类型的多芯光纤,与常见的多芯成像光纤不同,它是通过在制造过程中向光纤掺杂制备而成。无序安德森定位光纤通常具有随机折射率分布,该无序结构可引起光在光纤中传播时的局域化,这种独特的非线性光学特性可以减少信号的损失和散射^[88]。

2018年,美国中佛罗里达大学 Zhao 等^[89]采用基于 U-Net 架构的神经网络实现了在不同弯曲状态下的无序光纤图像重建,如图 5 所示。该研究团队还进一步在实验平台中加入加热器以同步测试深度学习驱动的无序光纤成像系统在温度变化、弯折等不同外界影响下的鲁棒性^[87],实验证明了该系统能对几毫米外的染

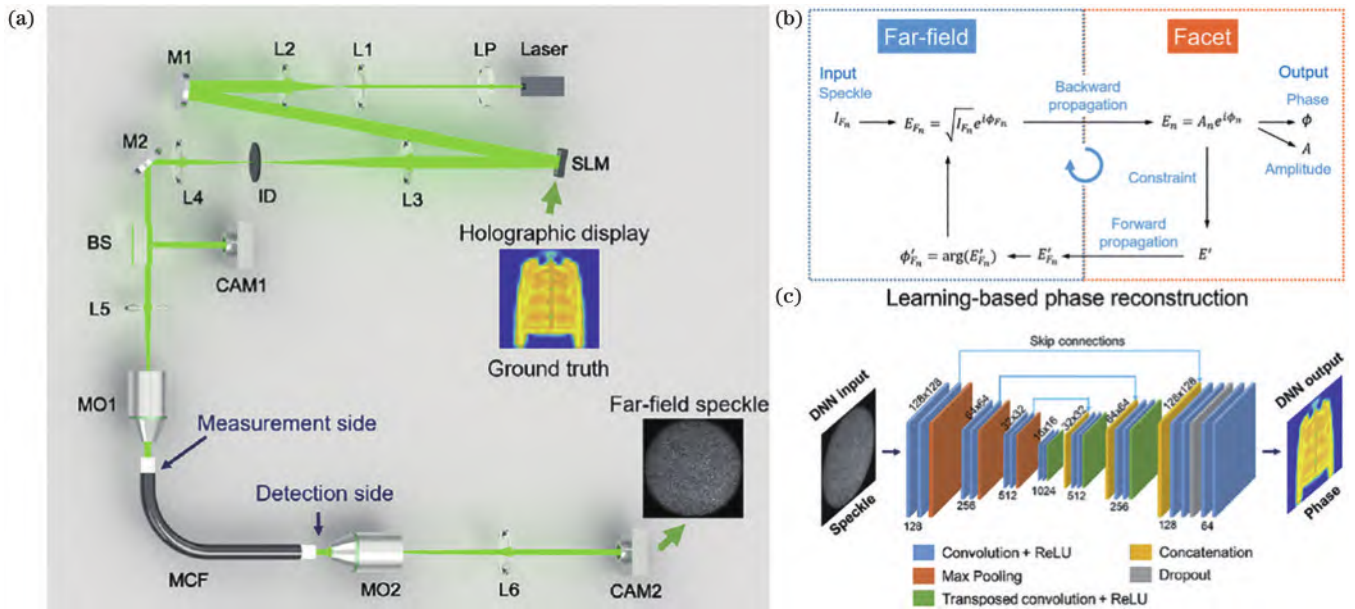


图4 基于多芯光纤的智能相位成像系统^[4]。(a)基于多芯光纤的定量相位成像数据集采集系统;(b)传统迭代式定量相位成像算法流程;(c)基于U-Net的定量相位成像重建模型

Fig. 4 Intelligent phase imaging system based on multi-core fiber^[4]. (a) Data acquisition system of quantitative phase imaging based on multi-core fiber; (b) traditional iterative quantitative phase imaging algorithm procedure; (c) quantitative phase imaging reconstruction model based on U-Net

色生物样品实现无透镜高质量成像。在此基础上,该团队提出了一种全新的无监督图像重建方法用于无序光纤成像,先使用实验对象的统计数据对光纤输出图像进行逐像素标准化,之后利用GAN以无监督的方式恢复图像细节^[90]。该方法提高了深度学习驱动的无序安德森定位光纤成像系统的稳健性,能够在多种条件下实现高分辨率、全彩色成像,开辟了将无监督学习方法应用于光纤图像重建的新思路。

4 深度学习驱动的多模光纤成像

4.1 基于多模光纤的智能散斑成像

前文介绍了一些多芯光纤智能成像的代表性工作,光场在多芯成像光纤的每个独立纤芯中一般以单模形式传输,而多模光纤能够在同一个纤芯中同时传输几十至数千个模式,理论上具有高空间带宽积的成像潜力,具备该特性的光纤能在直径仅有240 μm的多模光纤探针中实现突破衍射极限的高分辨率成像^[91]。然而,受模式耦合和模间色散的限制,光在多模光纤中的复杂传播过程给图像重建带来了巨大的困难。多模光纤中的复杂光场传播特性通常可以由数字全息技术直接测量并通过传输矩阵表征^[92],其中的每个元素定义了光纤输入端与输出端各模式之间的量化对应关系。在已测得传输矩阵的前提下,可通过空间光调制器等可编程光学器件或通过计算光学成像方法逆转或调节传输矩阵,校正由模式耦合和模间色散引起的像差,从而通过多模光纤实现光场调控、成像以及信息传输等^[26,93-97]。然而,完全精确地表征传输矩阵至少需要

与光纤模式数量相同的测量次数,且相较于多芯光纤,多模光纤成像更易受光的波长、偏振、温度、弯折等外界物理因素影响。

得益于对图像间非线性关系的卓越学习能力,深度神经网络可以有效地映射多模光纤的输入图像与输出图像的之间的复杂关系,实现从混乱信号中重建出清晰图像。2018年,瑞士洛桑联邦理工学院Psaltis与Moser的联合研究团队^[60,98]验证了深度学习在多模光纤成像中的应用潜力,他们搭建了如图6(a)所示的实验系统,通过空间光调制器生成手写数字与字母图案样式的强度或相位真值图像,再投影至多模光纤远端端面,并通过显微镜系统采集光纤近端的输出散斑图像。在训练深度神经网络时,使用散斑图像作为输入,将在空间光调制器上生成的强度或相位真值图像作为标签监督神经网络的学习过程。图6(b)~(c)分别展示了用于多模光纤散斑重建的VGG^[98]和U-Net模型^[60],图7展示的实验结果证明基于监督学习的深度神经网络能够识别和重建多模光纤输出端的失真散斑图像,还可以直接恢复所输入手写数字、字母等样式的简单图像的强度或相位信息。

2021年,新加坡南洋理工大学Zhu等^[62]简化了用于多模光纤散斑重建的神经网络以提高图像重建速度和减少计算资源需求。2022年,上海理工大学Xu等^[100]进一步提高了基于深度学习的多模光纤对复杂图像的成像精度和可靠性。如图6(d)所示,北京邮电大学Yu等^[99]采用GAN实现了多模光纤的散斑成像,在相同的成像性能下,与U-Net模型相比需要的训




图5 深度学习驱动无序安德森定位光纤成像系统^[87]。(a)基于无序安德森定位光纤的成像系统;(b)基于深度学习的无序安德森定位光纤散斑重建模型;(c)多种细胞的真实图像以及对应的无序安德森光纤散斑图像和重建图像

Fig. 5 Disordered Anderson positioning optical fiber imaging system driven by deep learning^[87]. (a) Imaging system based on disordered Anderson localizing fiber; (b) disordered Anderson localizing fiber speckle reconstruction model based on deep learning; (c) real images of various cells, corresponding disordered Anderson fiber speckle images and reconstructed images

练数据量更少,特征提取能力更强。2021年,瑞士洛桑联邦理工学院 Psaltis 课题组^[101-102]深入探究了全息技术与传统光强技术的差异及其对成像质量的影响,

比较了在全息与不同强度成像模态下,神经网络对多模光纤散斑的重建效果,结果表明即使没有完整的光场信息,仅使用强度信息也能达到较高的图像重建性

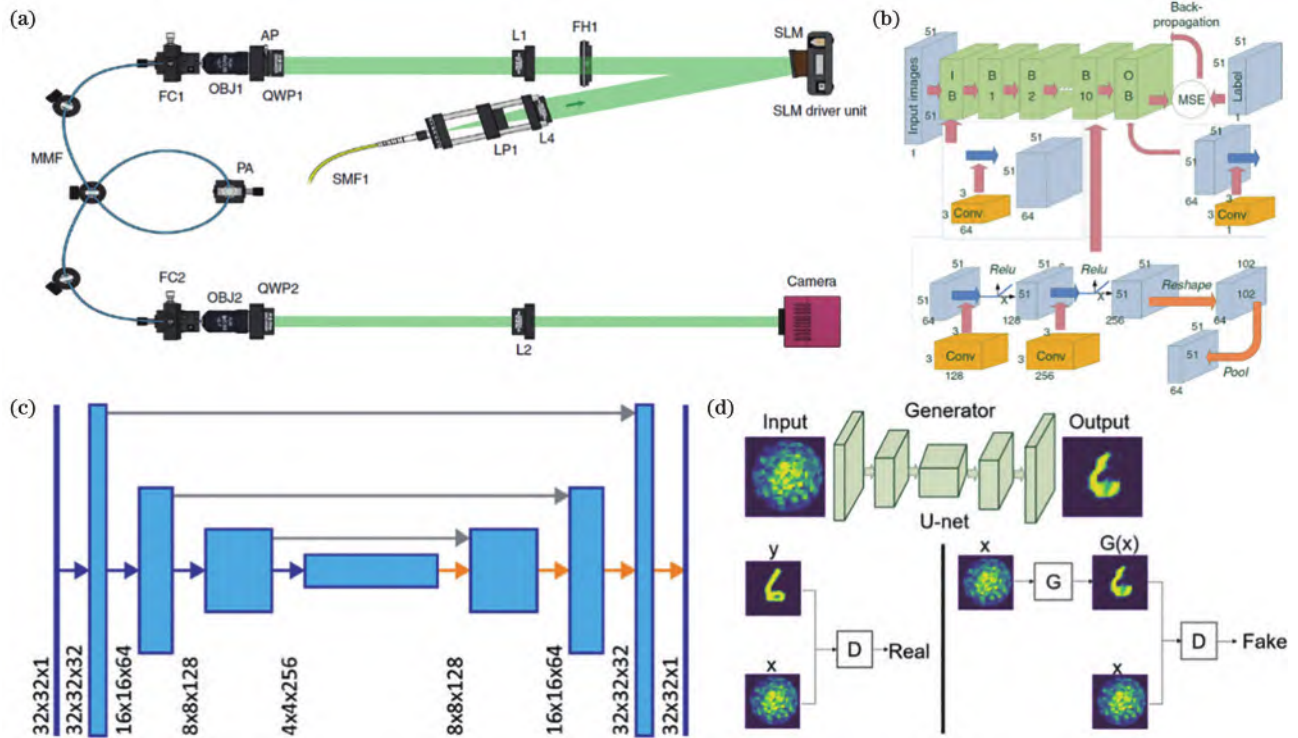


图6 基于多模光纤的智能散斑成像系统^[60,98-99]。(a)多模光纤散斑成像系统;(b)基于VGG的散斑重建模型;(c)基于U-Net的散斑重建模型;(d)基于GAN的散斑重建模型

Fig. 6 Intelligent speckle imaging system based on multimode fiber^[60,98-99]. (a) Multi-mode fiber speckle imaging system; (b) speckle reconstruction model based on VGG; (c) speckle reconstruction model based on U-Net; (d) speckle reconstruction model based on GAN

能,并发现神经网络使用光纤散斑进行图像分类的性能不依赖于测试的散斑位置,这一发现也在同类研究中得到证实^[102-103],这表明深度学习模型对多模光纤散斑重建任务具有较好的泛化性和稳健性。

多模光纤的信号传输过程易受弯折、温度改变等外界物理因素影响,虽然神经网络对较弱的环境信号扰动有一定的鲁棒性,但该性能依赖于训练数据的质量和多样性,如果训练数据没有涵盖这些物理因素造成的输入变化,神经网络在面对这些未知的变化时可能无法正确处理传输信号。2022年,以色列希伯来大学Bromberg课题组^[59]的研究结果证实,随着光纤弯曲状态的改变,基于同一输入图像的光纤散斑图之间的相似度会逐渐降低。若散斑重建模型的训练集中只包含单一弯曲状态下的光纤散斑图,则重建图像的可信度将随散斑相似度的降低而降低。然而,若训练集中包含多种弯曲状态下的光纤散斑图,则模型的成像稳定性将得到显著提升。因此,为了进一步提升深度学习驱动的多模光纤成像在外界物理因素影响下的鲁棒性,研究人员在实验数据收集系统中引入光纤形变、温度变化等外界环境影响因素^[59,104-107],通过丰富训练数据的多样性实现具有较强抗干扰能力的多模光纤智能散斑重建。近期在抗扰动成像的基础上,研究人员通过深度学习算法进一步实现了基于多模光纤的宽场成像^[105]和高景深成像^[59]。

上述散斑重建主要依赖于数据驱动的深度学习方法,其成像效果取决于数据的质量和多样性,但在数据量不足的情况下其可靠性与可解释性较为不足,而物理信息神经网络同时具有深度学习的强大非线性拟合能力与物理模型的严格约束,能够提供准确、可靠且符合物理规律的图像重建方法。南京理工大学Han课题组^[108]将散斑关联理论与深度学习相结合,将物理信息神经网络用于多模光纤的抗干扰成像,实现了任意光纤长度下的稳定动态成像。荷兰阿姆斯特丹自由大学Amitonova课题组^[109]将实验得到的物理先验信息作为深度学习中的损失函数,软硬件同步以无监督的方式训练神经网络,验证了物理信息神经网络实现多模光纤超分辨率成像的可能性。总之,深度学习提供了一种拟合多模光纤中非线性光场传播过程的新方法和新思路,展示出广阔的应用前景和潜在的研究价值。

4.2 基于时频域信息的多模光纤智能成像

通常情况下,多模光纤中的色散会降低光纤图像重建质量。2022年,清华大学Liu等^[110]利用多模光纤中的模式色散效益,实现了 1.54×10^7 pixel/s的超高速成像。如图8所示,该团队利用脉冲激光照射被测物体,经过1 km长的多模光纤传输,被测物体的空间分布信息经过模式色散后被编码为一维时序信号,并使用训练后的深度神经网络从多模光纤输出端的时序信号中重建输入端的脉冲空间图像。该系统能在极短的

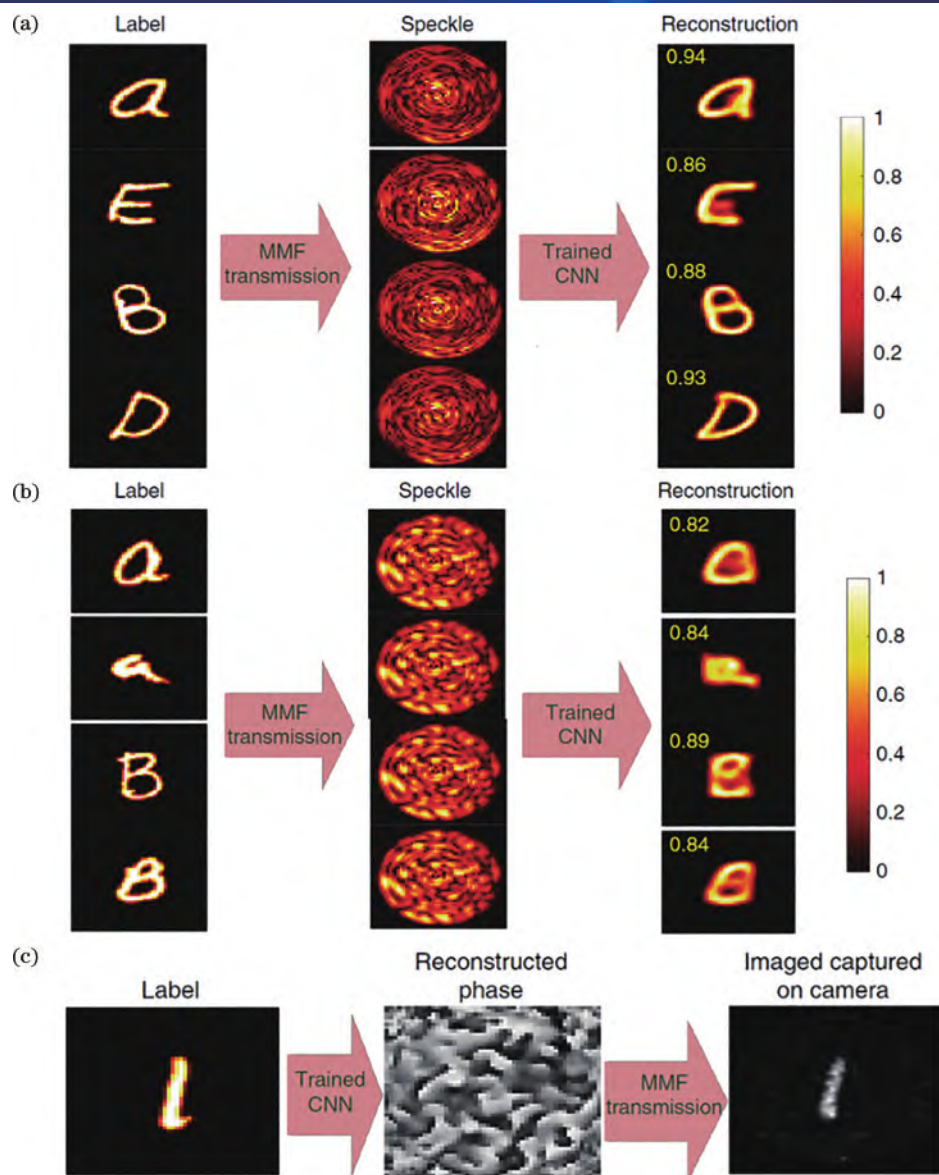


图7 基于多模光纤的手写拉丁字母对应散斑重建图^[98]。(a)模型从输出幅度散斑图重建输入幅度图;(b)模型从输出幅度散斑图重建输入相位图;(c)模型通过真实图像预测对应的空间光调制器相位图,经过多模光纤后,真实图像在相机上实现重建

Fig. 7 Speckle reconstruction diagram of handwritten Latin letters based on multi-mode fiber^[98]. (a) Model reconstructs input amplitude image from output amplitude speckle; (b) model reconstructs input phase image from output amplitude speckle; (c) model predicts corresponding spatial light modulator phase image through real image, and real image is reconstructed on the camera after passing through the multi-mode fiber

时间内拍摄大量连续图像,在快速动态过程成像领域中具有广阔的应用前景。

相较于单模光纤,多模光纤天然具有高带宽优势。英国玛丽王后学院 Fan 等^[58]通过深度学习解码空间信息,在一根多模光纤内同时传输 400 信道的信息。另一方面,通过控制多模光纤入射光波长或偏振,也可以构建不同的光谱和偏振信道,以实现多通道的图像传输。南京大学 Xu 课题组^[111]通过深度学习实现了 8 个光谱或 9 个偏振信道中多模光纤强度图像重建并对信道进行了分类。

4.3 智能多模光纤成像在计算机视觉任务上的应用

由于多模光纤中的光场传输过程较为复杂,目前

基于深度学习的多模光纤成像仍局限于较为简单的图像,且分辨率较低,难以将常见的计算机视觉模型直接应用于光纤成像。因此,如图 9 所示,针对计算机视觉中常见的下游任务,2022 年,北京邮电大学 Wu 等^[112]提出了端到端的多模光纤边缘检测神经网络,该神经网络不需要先重建图像再进行边缘检测,而是直接通过光强信息获得目标的边缘信息。与从多模光纤重建图像中提取边缘信息的传统方法相比,端到端的多模光纤边缘检测神经网络可以显著减少测量次数,并具有更好的边缘检测效果。类似的端到端模型还可以应用于多模光纤图像分类^[113]、去噪^[114]等任务中,并均通过实验验证了其具有更高的效率与精度,有助于推动

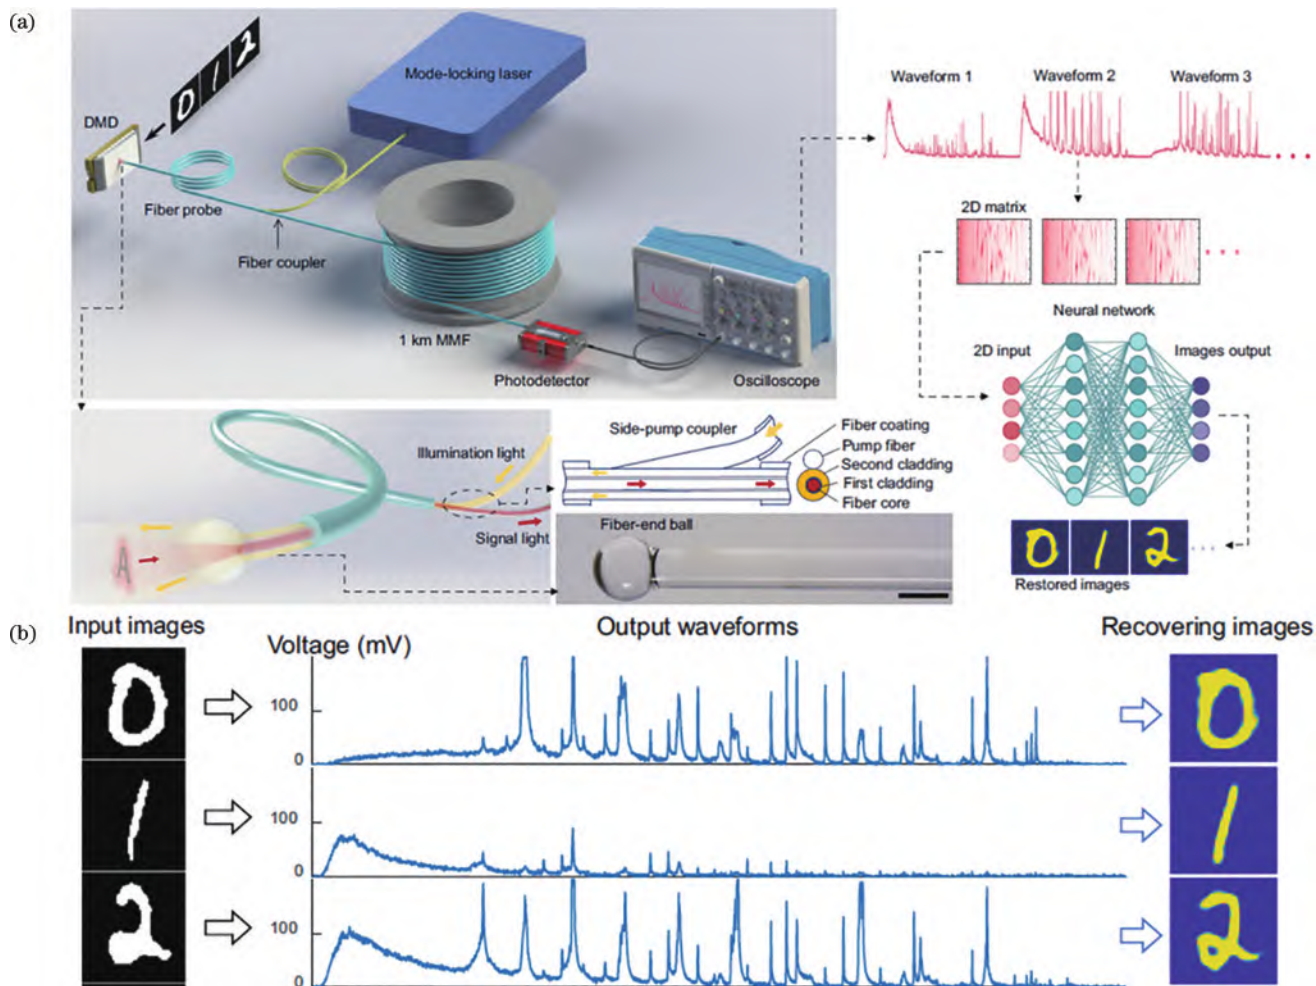


图8 基于多模光纤的一维时序信号对应的图像重建系统^[110]。(a)真实图像对应的一维时序信号采集系统和图像重建模型;(b)真实图像以及其所对应的一维时序信号和重建图像

Fig. 8 Image reconstruction system of one-dimensional temporal signal based on multi-mode optical fiber^[110]. (a) Data acquisition system of one-dimensional temporal signal corresponding to real image, and image reconstruction model; (b) real image, its corresponding one-dimensional temporal signal and reconstructed image

多模光纤成像在特殊极端场景下的视觉任务中的应用。

5 讨论与展望

5.1 现有进展

在光纤成像领域,深度学习技术已在算法优化、图像质量提升、扩展应用场景等方面展现出其强大能力与广阔的应用前景。在多芯光纤成像中,深度学习能助力解决非相干成像中的蜂窝状伪影与相干成像中的相位失真等问题,减少多芯光纤成像所需的时间与提高空间分辨率。在多模光纤成像中,基于深度学习的神经网络提供了拟合光纤输入与输出映射关系的新方法,大幅提升图像重建速度,并赋予多模光纤相位成像、光谱成像、偏振成像等多种成像模态。

相较于传统算法,深度学习算法在光纤成像中的优势主要体现在图像处理速度、成像质量两方面。在图像处理速度方面,频域滤波、相位恢复、压缩感知等光纤成像常用的传统图像处理算法通常需要逐像素处

理或迭代运算,计算量大且迟缓,难以对高分辨率图像进行实时处理;而经过预训练的深度学习模型,其成像过程主要涉及前向传播计算,并且能够利用图形处理器(GPU)的并行计算能力有效提升系统的图像处理效率,实现实时高清图像处理。在成像质量方面,传统算法依赖于精确的光学物理模型和先验信息,在具备精确测量先验信息的情况下效果较佳,但对图像中噪声和环境变化较为敏感;深度学习算法具有强大的特征学习和非线性映射能力,特别擅长从低质量数据中恢复高质量图像,如在光纤散斑成像中,深度学习模型可从严重失真的散斑图像中恢复出较为准确的图像信息,且能在一定限度内的环境变化下稳定工作。总之,深度学习在需要处理大量数据和实时成像的应用中具有一定的优势,尽管深度学习模型需要大量的数据和计算资源进行训练,但训练后模型的计算速度和成像质量通常高于传统算法。

5.2 问题和挑战

目前,基于深度学习的光纤成像技术仍面临着诸

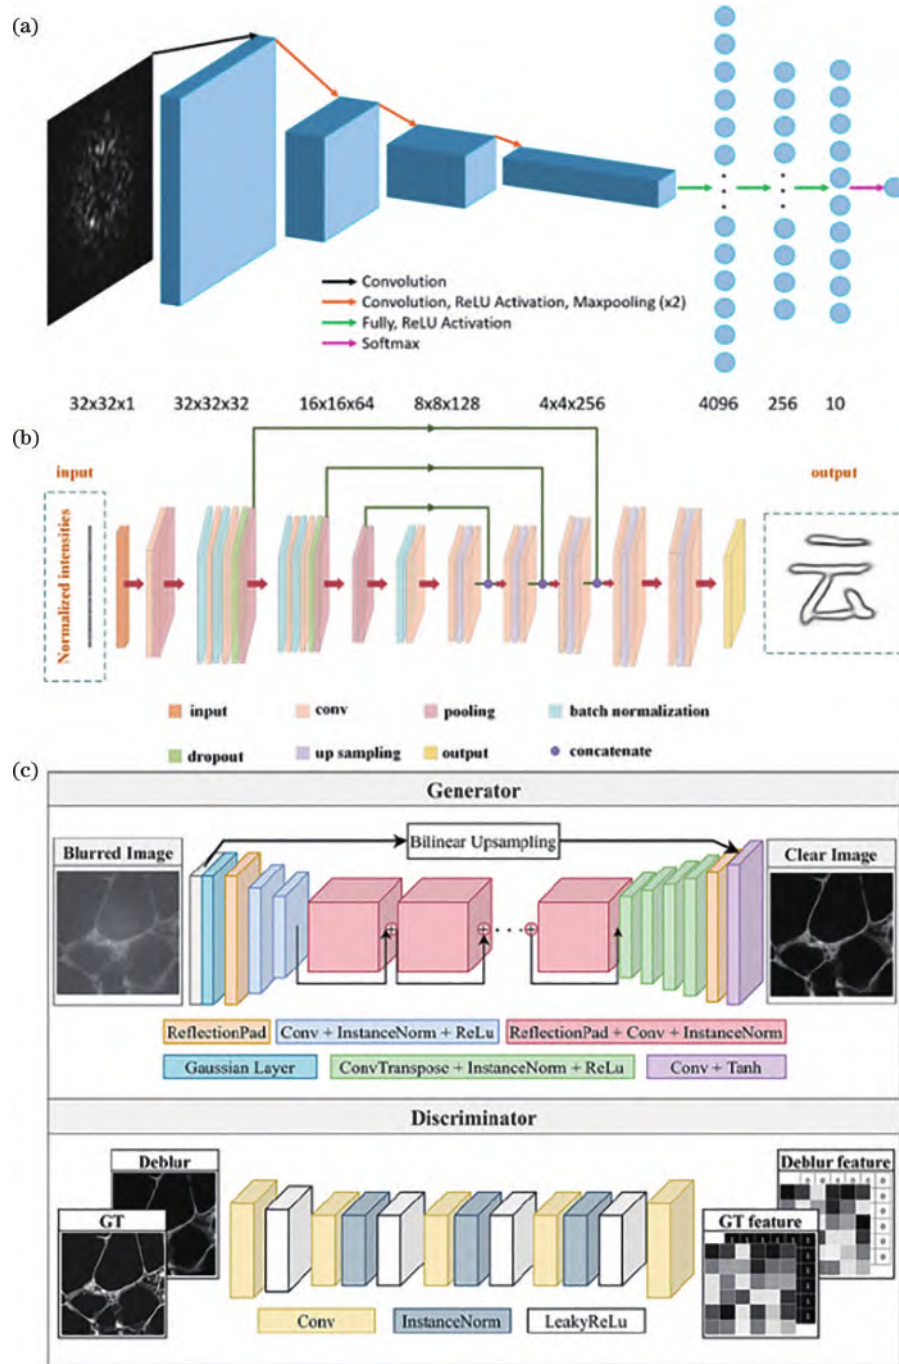


图9 多模光纤成像在计算机视觉任务中的应用^[112-114]。(a)基于多模光纤散斑的图像分类;(b)基于多模光纤散斑的边缘检测;(c)基于多模光纤散斑的图像去噪

Fig. 9 Application of multi-mode fiber imaging in computer vision tasks^[112-114]. (a) Image classification based on multi-mode fiber speckle; (b) edge detection based on multi-mode fiber speckle; (c) image denoising based on multi-mode fiber speckle

多问题和挑战, 本文将从数据、鲁棒性和方法三个方面进行分析。在数据上, 光纤成像相关的高质量数据依然十分稀缺。首先, 深度学习模型在重建图像任务中, 需要尽可能保持训练集中输入图像和重建图像在空间位置上的对应关系, 以此推动模型性能的提升。然而, 由于光纤成像过程中不可避免会存在误差, 真实图像与光纤输出图像难以在时间和空间上实现准确匹配。尽管图像平移、旋转等后处理方法可以在一定程度上缓解这一问题, 但无法完全解决。然后, 不同研究中使

用的光纤成像系统存在差异, 缺乏统一的实验平台。这种差异会导致深度学习模型的重建结果随着系统的变化而产生显著差异, 从而难以有效评估模型性能。最后, 多数研究中使用的光纤散斑数据集尚未开源, 深度学习作为一种数据驱动方法, 其性能与训练数据量密切相关。随着数据集样本量的增加和来源的多样化, 深度学习模型的性能将会进一步提升、应用范围也会更广泛, 且模型的评估将更加准确。

在鲁棒性上, 深度学习驱动的光纤成像在处理复

杂图像和抵抗外界干扰的能力上仍有待提升。目前已有的光纤智能成像系统大多通过 MNIST (Mixed national institute of standards and technology) 和 FashionMNIST 数据集进行测试^[115-116]。这两个数据集包含的图像结构较为简单,主要是手写数字和服装图像,与实际应用场景中光纤成像处理的复杂显微图像存在显著差距。当实验图像转变为更复杂的 ImageNet 图像时,重建图像的质量会显著下降^[117]。此外,光纤成像技术在特定领域图像上的应用能力也有待进一步测试。例如在医学领域,基于深度学习的光纤成像对癌细胞、人体组织等医学图像的相关实验较少,无法充分验证其有效性。同时,基于深度学习的光纤成像在抗干扰能力方面也面临较大挑战。在光纤成像过程中,光纤的弯曲程度、外界温度的变化、入射光频率的变化等因素都会影响生成的散斑图像,从而影响重建图像的质量。目前已有研究测试了外界因素对光纤成像质量的影响,并通过引入干扰来扩展模型的数据集,以提高散斑重建模型的鲁棒性^[18]。然而,目前的光纤智能成像技术仍对外界环境较为敏感,难以在外界环境发生较大变化时保持较高的成像质量。

在方法上,如何更好地将深度学习模型与光纤成像领域相结合仍是一个需要深入研究的课题。目前,深度学习模型在光纤成像领域的应用大多采用端到端的形式实现图像重建或预测^[118]。这种方式虽然在实现上最为简便,但并没有充分利用光纤成像领域已有的专业知识,例如光纤成像的物理特性和光学原理等。这些专业知识可以为深度学习模型提供更多信息,从

而提高模型的性能和可靠性。此外,对于光纤成像的不同应用领域,深度学习模型需要与具体任务特征相结合。例如,在医学图像处理、工业检测等不同场景中,图像特征与成像需求并不相同。深度学习模型需要充分考虑任务的特性和需求,针对特定任务进行优化和调整。

随着深度学习算法在光纤成像领域的不断应用,越来越多的研究者意识到其作为一种新型计算成像方法的优越性,并通过它不断突破传统方法的限制,推动光纤成像在质量和效率上的不断提高。然而,模型、鲁棒性和方法这三方面的因素使得这些创新距离实际应用仍存在一定的差距,需要进一步的研究来充分利用深度学习推动光纤成像领域的发展。

5.3 未来展望

目前,已有最新的研究将智能光纤成像技术应用到生物医学领域,如在全透镜光纤内窥镜领域,深度学习驱动的计算成像方法可将内窥镜探针直径缩小至几百微米,极大减少其侵入性。如图 10(a)所示,传统脑部活检需要先侵入体内取样,再对组织切片染色后由病理医生诊断,流程繁琐且耗时较长。而智能全透镜光纤内窥镜[图 10(b)]具有极低的侵入性且成像分辨率较高,有望直接对体内的肿瘤组织进行微创显微成像,并进一步通过可解释的分类神经网络进行智能快速诊断^[83],为癌症早期诊断提供了新思路与新方法。在工业检测领域,深度学习算法可以大幅提升工业光纤内窥镜的分辨率与图像质量,进而提高检测精度与效率。

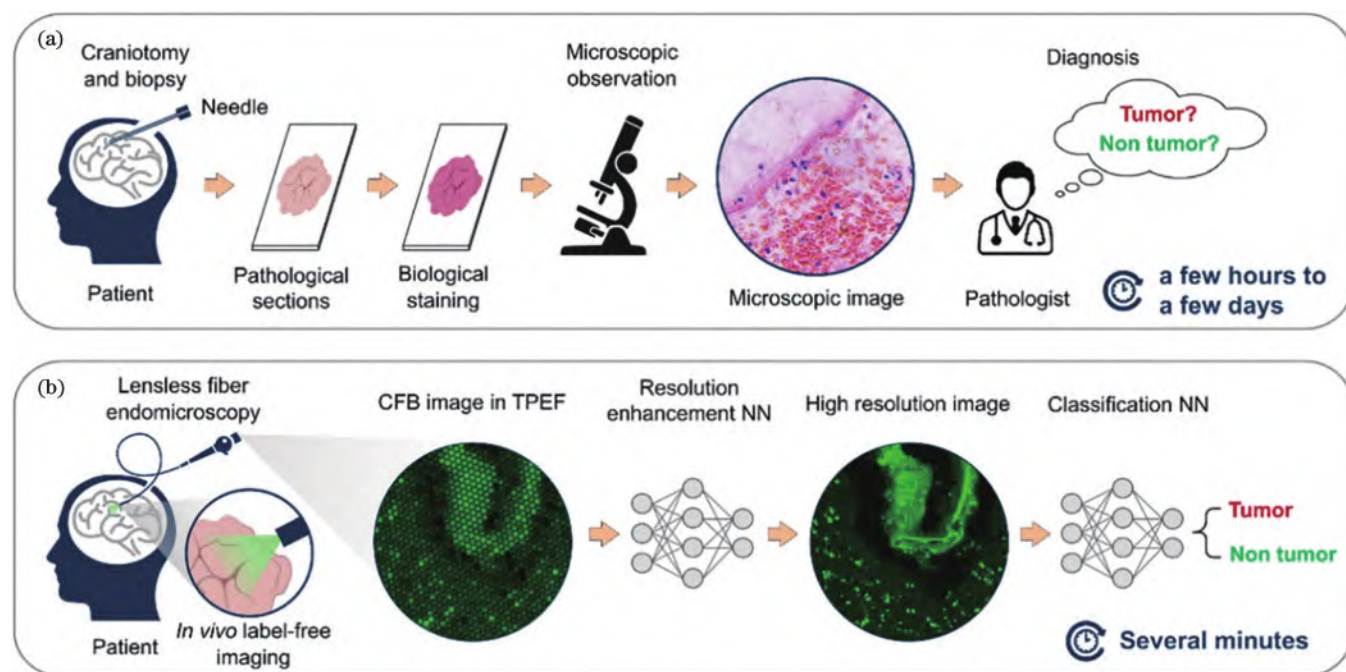


图 10 肿瘤诊断活检工作流程对比^[83]。(a) 传统活检流程;(b) 基于智能无透镜光纤成像的端到端活检单击或点击此处输入文字
Fig. 10 Comparison of cancer diagnosis biopsy workflows^[83]. (a) Traditional biopsy procedure; (b) end-to-end biopsy based on intelligent lensless fiber imaging

6 总 结

介绍了深度学习技术在光纤成像领域中的相关应用,主要围绕着多芯光纤与多模光纤这两类常见成像光纤展开,简单展示了荧光成像、定量相位成像、散斑成像、光谱成像等多种光纤成像模态中应用深度学习模型突破瓶颈的代表性工作。目前,深度学习与光纤成像仍为新兴的前沿交叉研究领域,面向实际的生物医学、工业检测、高带宽通信等应用场景,系统的稳健性、泛化性仍有较大的提升空间。相信深度学习与计算成像技术的不断进步必将带动光纤成像性能的变革性提升,大幅拓展光纤成像的实际应用场景,为光纤成像的发展铺平道路。

参 考 文 献

- [1] Kuschmierz R, Scharf E, Ortégón-González D F, et al. Ultra-thin 3D lensless fiber endoscopy using diffractive optical elements and deep neural networks[J]. *Light: Advanced Manufacturing*, 2021, 2(4): 415-424.
- [2] Sun J W, Yang B, Koukourakis N, et al. AI-driven projection tomography with multicore fibre-optic cell rotation[J]. *Nature Communications*, 2024, 15: 147.
- [3] Sun J W, Wu J C, Wu S, et al. Quantitative phase imaging through an ultra-thin lensless fiber endoscope[J]. *Light: Science & Applications*, 2022, 11(1): 204.
- [4] Sun J W, Zhao B, Wang D, et al. Calibration-free quantitative phase imaging in multi-core fiber endoscopes using end-to-end deep learning[J]. *Optics Letters*, 2024, 49(2): 342-345.
- [5] 贺正权, 任立勇, 庄斌, 等. 单光纤成像技术[J]. *激光与光电子学进展*, 2017, 54(3): 030005.
He Z Q, Ren L Y, Zhuang B, et al. Single optical fiber imaging technology[J]. *Laser & Optoelectronics Progress*, 2017, 54(3): 030005.
- [6] 卢顺, 谭中伟, 刘艳, 等. 利用神经网络实现多模光纤传输散斑的识别[J]. *光学学报*, 2020, 40(13): 1306001.
Lu S, Tan Z W, Liu Y, et al. Realization of recognition for multi-mode optical fiber transmission speckle using neural network[J]. *Acta Optica Sinica*, 2020, 40(13): 1306001.
- [7] 安康, 李汶芳, 段晓礁, 等. 光纤耦合 GAGG_Ce 型 X 射线探测器高分辨成像[J]. *光学学报*, 2022, 42(1): 0111001.
An K, Li W F, Duan X J, et al. Fiber-coupled GAGG_Ce X-ray detector for high-resolution imaging[J]. *Acta Optica Sinica*, 2022, 42(1): 0111001.
- [8] Kao K C, Hockham G A. Dielectric-fibre surface waveguides for optical frequencies[J]. *Proceedings of the Institution of Electrical Engineers*, 1966, 113(7): 1151-1158.
- [9] Li S H, Horsley S A R, Tyc T, et al. Memory effect assisted imaging through multimode optical fibres[J]. *Nature Communications*, 2021, 12: 3751.
- [10] Wang T J, Dremel J, Richter S, et al. Resolution-enhanced multi-core fiber imaging learned on a digital twin for cancer diagnosis[J]. *Neurophotonics*, 2024, 11(S1): S11505.
- [11] Yu Z P, Li H H, Zhong T T, et al. Wavefront shaping: a versatile tool to conquer multiple scattering in multidisciplinary fields[J]. *The Innovation*, 2022, 3(5): 100292.
- [12] Zhong T T, Qiu Z H, Wu Y, et al. Optically selective neuron stimulation with a wavefront shaping-empowered multimode fiber[J]. *Advanced Photonics Research*, 2022, 3(3): 2100231.
- [13] 程圣福, 仲天庭, 胡子敏, 等. 基于相干光调控的无透镜光纤成像及其应用(特邀)[J]. *激光与光电子学进展*, 2024, 61(6): 0618002.
Cheng S F, Zhong T T, Hu Z M, et al. Lensless fiber-optic imaging via coherent light modulation and its applications(invited)[J]. *Laser & Optoelectronics Progress*, 2024, 61(6): 0618002.
- [14] Rosen S, Gilboa D, Katz O, et al. Focusing and scanning through flexible multimode fibers without access to the distal end[EB/OL]. (2015-06-29) [2024-05-06]. <http://arxiv.org/abs/1506.08586v1>.
- [15] Weiss U, Katz O. Two-photon lensless micro-endoscopy with in situ wavefront correction[J]. *Optics Express*, 2018, 26(22): 28808-28817.
- [16] Cui M. Parallel wavefront optimization method for focusing light through random scattering media[J]. *Optics Letters*, 2011, 36(6): 870-872.
- [17] Conkey D B, Brown A N, Caravaca-Aguirre A M, et al. Genetic algorithm optimization for focusing through turbid media in noisy environments[J]. *Optics Express*, 2012, 20(5): 4840-4849.
- [18] Woo C M, Li H H, Zhao Q, et al. Dynamic mutation enhanced particle swarm optimization for optical wavefront shaping[J]. *Optics Express*, 2021, 29(12): 18420-18426.
- [19] Zhao Q, Woo C M, Li H H, et al. Parameter-free optimization algorithm for iterative wavefront shaping[J]. *Optics Letters*, 2021, 46(12): 2880-2883.
- [20] Yu H, Yao Z Y, Sui X B, et al. Focusing through disturbed multimode optical fiber based on self-adaptive genetic algorithm[J]. *Optik*, 2022, 261: 169129.
- [21] Woo C M, Zhao Q, Zhong T T, et al. Optimal efficiency of focusing diffused light through scattering media with iterative wavefront shaping[J]. *APL Photonics*, 2022, 7(4): 046109.
- [22] Cheng S F, Zhong T T, Woo C M, et al. Long-distance pattern projection through an unfixed multimode fiber with natural evolution strategy-based wavefront shaping [J]. *Optics Express*, 2022, 30(18): 32565-32576.
- [23] Kuschmierz R, Scharf E, Koukourakis N, et al. Self-calibration of lensless holographic endoscope using programmable guide stars[J]. *Optics Letters*, 2018, 43(12): 2997-3000.
- [24] Mezil S, Alpes U G, Wang I, et al. Imaging through a square multimode fiber by scanning focused spots with the memory effect[J]. *Optics Letters*, 2023, 48(17): 4811-4814.

- 4701-4704.
- [25] Papadopoulos I N, Simandoux O, Farahi S, et al. Optical-resolution photoacoustic microscopy by use of a multimode fiber[J]. *Applied Physics Letters*, 2013, 102(21): 211106.
 - [26] Morales-Delgado E E, Psaltis D, Moser C. Two-photon imaging through a multimode fiber[J]. *Optics Express*, 2015, 23(25): 32158-32170.
 - [27] Popoff S M, Lerosey G, Fink M, et al. Controlling light through optical disordered media: transmission matrix approach[J]. *New Journal of Physics*, 2011, 13(12): 123021.
 - [28] Zhong J S, Wen Z, Li Q Z, et al. Efficient reference-less transmission matrix retrieval for a multimode fiber using fast Fourier transform[J]. *Advanced Photonics Nexus*, 2023, 2(5): 056007.
 - [29] Plöschner M, Straka B, Dholakia K, et al. GPU accelerated toolbox for real-time beam-shaping in multimode fibres[J]. *Optics Express*, 2014, 22(3): 2933-2947.
 - [30] Yu H, Lee K, Park Y. Ultrahigh enhancement of light focusing through disordered media controlled by megapixel modes[J]. *Optics Express*, 2017, 25(7): 8036-8047.
 - [31] Zhao T R, Ourselin S, Vercauteren T, et al. Seeing through multimode fibers with real-valued intensity transmission matrices[J]. *Optics Express*, 2020, 28(14): 20978-20991.
 - [32] Zhao T R, Deng L, Wang W, et al. Bayes' theorem-based binary algorithm for fast reference-less calibration of a multimode fiber[J]. *Optics Express*, 2018, 26(16): 20368-20378.
 - [33] Choi Y, Yoon C, Kim M, et al. Scanner-free and wide-field endoscopic imaging by using a single multimode optical fiber[J]. *Physical Review Letters*, 2012, 109(20): 203901.
 - [34] Čizmar T, Dholakia K. Exploiting multimode waveguides for pure fibre-based imaging[J]. *Nature Communications*, 2012, 3: 1027.
 - [35] Deng L, Yan J D, Elson D S, et al. Characterization of an imaging multimode optical fiber using a digital micro-mirror device based single-beam system[J]. *Optics Express*, 2018, 26(14): 18436-18447.
 - [36] N'Gom M, Norris T B, Michielssen E, et al. Mode control in a multimode fiber through acquiring its transmission matrix from a reference-less optical system[J]. *Optics Letters*, 2018, 43(3): 419-422.
 - [37] Huang G Q, Wu D X, Luo J W, et al. Retrieving the optical transmission matrix of a multimode fiber using the extended Kalman filter[J]. *Optics Express*, 2020, 28(7): 9487-9500.
 - [38] Huang G Q, Wu D X, Luo J W, et al. Generalizing the Gerchberg-Saxton algorithm for retrieving complex optical transmission matrices[J]. *Photonics Research*, 2020, 9(1): 34-42.
 - [39] Cheng S F, Zhang X Y, Zhong T T, et al. Nonconvex optimization for optimum retrieval of the transmission matrix of a multimode fiber[J]. *Advanced Photonics Nexus*, 2023, 2(6): 066005.
 - [40] Vasquez-Lopez S A, Turcotte R, Koren V, et al. Subcellular spatial resolution achieved for deep-brain imaging in vivo using a minimally invasive multimode fiber[J]. *Light: Science & Applications*, 2018, 7: 110.
 - [41] Popoff S, Lerosey G, Fink M, et al. Image transmission through an opaque material[J]. *Nature Communications*, 2010, 1: 81.
 - [42] Zhao Q, Yu P P, Liu Y F, et al. Light field imaging through a single multimode fiber for OAM-multiplexed data transmission[J]. *Applied Physics Letters*, 2020, 116(18): 181101.
 - [43] Loterie D, Farahi S, Papadopoulos I, et al. Digital confocal microscopy through a multimode fiber[J]. *Optics Express*, 2015, 23(18): 23845-23858.
 - [44] Osnabrugge G, Horstmeyer R, Papadopoulos I N, et al. Generalized optical memory effect[J]. *Optica*, 2017, 4(8): 886-892.
 - [45] Liu H L, Lai P X, Han S S. Influence of anisotropy factor on the memory effect: a systematic study[J]. *Optik*, 2021, 231: 166366.
 - [46] Bertolotti J, van Putten E G, Blum C, et al. Non-invasive imaging through opaque scattering layers[J]. *Nature*, 2012, 491(7423): 232-234.
 - [47] Stasio N, Moser C, Psaltis D. Calibration-free imaging through a multicore fiber using speckle scanning microscopy[J]. *Optics Letters*, 2016, 41(13): 3078-3081.
 - [48] Amitonova L V, Mosk A P, Pinkse P W H. Rotational memory effect of a multimode fiber[J]. *Optics Express*, 2015, 23(16): 20569-20575.
 - [49] Gutiérrez-Cuevas R, Goetschy A, Pelc G, et al. Tailoring the rotational memory effect in multimode fibers [EB/OL]. (2024-01-12)[2024-05-06]. <https://arxiv.org/html/2310.19337v2>.
 - [50] Caravaca-Aguirre A M, Carron A, Mezil S, et al. Optical memory effect in square multimode fibers[J]. *Optics Letters*, 2021, 46(19): 4924-4927.
 - [51] Amitonova L V, de Boer J F. Compressive imaging through a multimode fiber[J]. *Optics Letters*, 2018, 43(21): 5427-5430.
 - [52] Caravaca-Aguirre A M, Singh S, Labouesse S, et al. Hybrid photoacoustic-fluorescence microendoscopy through a multimode fiber using speckle illumination[J]. *APL Photonics*, 2019, 4(9): 096103.
 - [53] Dong Z Y, Wen Z, Pang C L, et al. A modulated sparse random matrix for high-resolution and high-speed 3D compressive imaging through a multimode fiber[J]. *Science Bulletin*, 2022, 67(12): 1224-1228.
 - [54] Caravaca-Aguirre A M, Poisson F, Bouchet D, et al. Single-pixel photoacoustic microscopy with speckle illumination[J]. *Intelligent Computing*, 2023, 2: 11.
 - [55] Sun J W, Wu J C, Koukourakis N, et al. Real-time complex light field generation through a multi-core fiber with deep learning[J]. *Scientific Reports*, 2022, 12: 7732.
 - [56] Scharf E, Dremel J, Kuschmierz R, et al. Video-rate lensless endoscope with self-calibration using wavefront shaping[J]. *Optics Letters*, 2020, 45(13): 3629-3632.

- [57] 朱润泽, 徐飞. 基于时空域信息提取的多模光纤成像[J]. 激光与光电子学进展, 2023, 60(11): 1106011.
Zhu R Z, Xu F. Multimode fiber imaging based on temporal-spatial information extraction[J]. Laser & Optoelectronics Progress, 2023, 60(11): 1106011.
- [58] Fan P F, Ruddlesden M, Wang Y F, et al. Learning enabled continuous transmission of spatially distributed information through multimode fibers[J]. Laser & Photonics Reviews, 2021, 15(4): 2000348.
- [59] Resisi S, Popoff S M, Bromberg Y. Image transmission through a dynamically perturbed multimode fiber by deep learning[J]. Laser & Photonics Reviews, 2021, 15(10): 2000553.
- [60] Borhani N, Kakkava E, Moser C, et al. Learning to see through multimode fibers[J]. Optica, 2018, 5(8): 960-966.
- [61] 李小川, 刘桂华, 曹令, 等. 基于传像光纤成像的蜂窝效应伪影修复算法[J]. 激光与光电子学进展, 2023, 60(12): 1210010.
Li X C, Liu G H, Cao L, et al. Restoration algorithm for honeycomb artifacts based on optical fiber imaging[J]. Laser & Optoelectronics Progress, 2023, 60(12): 1210010.
- [62] Zhu C Y, Chan E A, Wang Y, et al. Image reconstruction through a multimode fiber with a simple neural network architecture[J]. Scientific Reports, 2021, 11: 896.
- [63] Caramazza P, Moran O, Murray-Smith R, et al. Transmission of natural scene images through a multimode fibre[J]. Nature Communications, 2019, 10: 2029.
- [64] Tonello A M, Letizia N A, Righini D, et al. Machine learning tips and tricks for power line communications[J]. IEEE Access, 2019, 7: 82434-82452.
- [65] Jiao L B, Huo L Z, Hu C M, et al. Refined UNet: UNet-based refinement network for cloud and shadow precise segmentation[J]. Remote Sensing, 2020, 12(12): 2001.
- [66] Dan Y B, Zhao Y, Li X, et al. Generative adversarial networks (GAN) based efficient sampling of chemical composition space for inverse design of inorganic materials[J]. NPJ Computational Materials, 2020, 6: 84.
- [67] Hsu K Y, Li H Y, Psaltis D. Holographic implementation of a fully connected neural network[J]. Proceedings of the IEEE, 1990, 78(10): 1637-1645.
- [68] Basha S H S, Dubey S R, Pulabaigari V, et al. Impact of fully connected layers on performance of convolutional neural networks for image classification[J]. Neurocomputing, 2020, 378: 112-119.
- [69] Situ G H. Deep holography[J]. Light: Advanced Manufacturing, 2022, 3(2): 278-300.
- [70] Ronneberger O, Fischer P, Brox T. U-net: convolutional networks for biomedical image segmentation[M]//Navab N, Hornegger J, Wells W M, et al. Medical image computing and computer-assisted intervention- MICCAI 2015. Lecture notes in computer science. Cham: Springer, 2015, 9351: 234-241.
- [71] Goodfellow I, Pouget-Abadie J, Mirza M, et al. Generative adversarial networks[J]. Communications of the ACM, 2020, 63(11): 139-144.
- [72] Sun J W, Kuschmierz R, Katz O, et al. Lensless fiber endomicroscopy in biomedicine[J]. Photonix, 2024, 5(1): 18.
- [73] Lee C Y, Han J H. Integrated spatio-spectral method for efficiently suppressing honeycomb pattern artifact in imaging fiber bundle microscopy[J]. Optics Communications, 2013, 306: 67-73.
- [74] Shao J B, Liao W C, Liang R G, et al. Resolution enhancement for fiber bundle imaging using maximum a posteriori estimation[J]. Optics Letters, 2018, 43(8): 1906-1909.
- [75] Dumas J P, Lodhi M A, Taki B A, et al. Computational endoscopy: a framework for improving spatial resolution in fiber bundle imaging[J]. Optics Letters, 2019, 44(16): 3968-3971.
- [76] Lee C Y, Han J H. Elimination of honeycomb patterns in fiber bundle imaging by a superimposition method[J]. Optics Letters, 2013, 38(12): 2023-2025.
- [77] Wang H D, Rivenon Y, Jin Y Y, et al. Deep learning enables cross-modality super-resolution in fluorescence microscopy[J]. Nature Methods, 2019, 16(1): 103-110.
- [78] Ravi D, Szczotka A B, Shakir D I, et al. Effective deep learning training for single-image super-resolution in endomicroscopy exploiting video-registration-based reconstruction[J]. International Journal of Computer Assisted Radiology and Surgery, 2018, 13(6): 917-924.
- [79] Wang B W, Li L, Yang H B, et al. Model-based deep learning for fiber bundle infrared image restoration[J]. Defence Technology, 2023, 27: 38-45.
- [80] Shao J B, Zhang J C, Huang X, et al. Fiber bundle image restoration using deep learning[J]. Optics Letters, 2019, 44(5): 1080-1083.
- [81] Shao J B, Zhang J C, Liang R G, et al. Fiber bundle imaging resolution enhancement using deep learning[J]. Optics Express, 2019, 27(11): 15880-15890.
- [82] Lee C Y, Han J H. Elimination of honeycomb patterns in fiber bundle imaging by a superimposition method[J]. Optics Letters, 2013, 38(12): 2023-2025.
- [83] Wu J C, Wang T J, Uckermann O, et al. Learned end-to-end high-resolution lensless fiber imaging towards real-time cancer diagnosis[J]. Scientific Reports, 2022, 12: 18846.
- [84] Lich J, Glosemeyer T, Czarske J, et al. Single-shot 3D incoherent imaging with diffuser endoscopy[J]. Light: Advanced Manufacturing, 2024, 5(1): 15.
- [85] Park Y, Depeursinge C, Popescu G. Quantitative phase imaging in biomedicine[J]. Nature Photonics, 2018, 12: 578-589.
- [86] Mafi A, Ballato J, Koch K W, et al. Disordered Anderson localization optical fibers for image transport: a review[J]. Journal of Lightwave Technology, 2019, 37(22): 5652-5659.
- [87] Zhao J, Hu X W, Gausmann S, et al. Learning-based image transport through disordered optical fibers with transverse Anderson localization[J]. Frontiers in Physics, 2023, 11: 1158452.

- 2021, 9: 710351.
- [88] Zhao J, Sun Y Y, Zhu Z Y, et al. Deep learning imaging through fully-flexible glass-air disordered fiber[J]. *ACS Photonics*, 2018, 5(10): 3930-3935.
- [89] Zhao J, Sun Y Y, Zhu H B, et al. Deep-learning cell imaging through Anderson localizing optical fiber[J]. *Advanced Photonics*, 2019, 1(6): 066001.
- [90] Hu X W, Zhao J, Antonio-Lopez J E, et al. Unsupervised full-color cellular image reconstruction through disordered optical fiber[J]. *Light: Science & Applications*, 2023, 12(1): 125.
- [91] Wen Z, Dong Z Y, Deng Q L, et al. Single multimode fibre for in vivo light-field-encoded endoscopic imaging [J]. *Nature Photonics*, 2023, 17: 679-687.
- [92] Turtaev S, Leite I T, Altwegg-Boussac T, et al. High-fidelity multimode fibre-based endoscopy for deep brain in vivo imaging[J]. *Light: Science & Applications*, 2018, 7: 92.
- [93] Rothe S, Radner H, Koukourakis N, et al. Transmission matrix measurement of multimode optical fibers by mode-selective excitation using one spatial light modulator[J]. *Applied Sciences*, 2019, 9(1): 195.
- [94] Plöschner M, Tyc T, Čížmár T. Seeing through chaos in multimode fibres[J]. *Nature Photonics*, 2015, 9: 529-535.
- [95] Ju Z Y, Yu Z M, Meng Z Y, et al. Simultaneous illumination and imaging based on a single multimode fiber[J]. *Optics Express*, 2022, 30(9): 15596-15606.
- [96] Trägårdh J, Pikálek T, Šerý M, et al. Label-free CARS microscopy through a multimode fiber endoscope[J]. *Optics Express*, 2019, 27(21): 30055-30066.
- [97] Lee S Y, Parot V J, Bouma B E, et al. Confocal 3D reflectance imaging through multimode fiber without wavefront shaping[J]. *Optica*, 2022, 9(1): 112-120.
- [98] Rahmani B, Loterie D, Konstantinou G, et al. Multimode optical fiber transmission with a deep learning network[J]. *Light: Science & Applications*, 2018, 7: 69.
- [99] Xu R C, Zhang L H, Chen Z Y, et al. High accuracy transmission and recognition of complex images through multimode fibers using deep learning[J]. *Laser & Photonics Reviews*, 2023, 17(1): 2200339.
- [100] Yu Z M, Ju Z Y, Zhang X L, et al. High-speed multimode fiber imaging system based on conditional generative adversarial network[J]. *Chinese Optics Letters*, 2021, 19(8): 081101.
- [101] Kakkava E, Rahmani B, Borhani N, et al. Imaging through multimode fibers using deep learning: the effects of intensity versus holographic recording of the speckle pattern[J]. *Optical Fiber Technology*, 2019, 52: 101985.
- [102] Chen Y C, Song B B, Wu J X, et al. Deep learning for efficiently imaging through the localized speckle field of a multimode fiber[J]. *Applied Optics*, 2023, 62(2): 266-274.
- [103] Zhang Y Z, Wu H, Zhao H, et al. Reconstructing images through multimode fibers from the up-conversion speckle patterns via deep learning[J]. *IEEE Access*, 2023, 11: 55561-55568.
- [104] Zhu R Z, Luo J X, Zhou X X, et al. Anti-perturbation multimode fiber imaging based on the active measurement of the fiber configuration[J]. *ACS Photonics*, 2023, 10(10): 3476-3483.
- [105] Fan P F, Wang Y F, Ruddlesden M, et al. Deep learning enabled scalable calibration of a dynamically deformed multimode fiber[J]. *Advanced Photonics Research*, 2022, 3(10): 2100304.
- [106] Feng Z F, Yue Z Q, Zhou W, et al. Optimizing anti-perturbation capability in single-shot wide-field multimode fiber imaging systems[J]. *Applied Physics Letters*, 2024, 124(10): 101112.
- [107] Ilaria C, Cosimo L, Georg R, et al. Roadmap on multimode photonics[J]. *Journal of Optics*, 2022, 24(8): 083001.
- [108] Guo E L, Zhou C Y, Zhu S, et al. Dynamic imaging through random perturbed fibers via physics-informed learning[J]. *Optics & Laser Technology*, 2023, 158: 108923.
- [109] Li W, Abrashitova K, Amitonova L V. Super-resolution multimode fiber imaging with an untrained neural network [J]. *Optics Letters*, 2023, 48(13): 3363-3366.
- [110] Liu Z T, Wang L L, Meng Y, et al. All-fiber high-speed image detection enabled by deep learning[J]. *Nature Communications*, 2022, 13: 1433.
- [111] Zhu R Z, Feng H G, Xu F. Deep learning-based multimode fiber imaging in multispectral and multipolarimetric channels[J]. *Optics and Lasers in Engineering*, 2023, 161: 107386.
- [112] Wu G H, Song Z X, Hao M, et al. Edge detection in single multimode fiber imaging based on deep learning[J]. *Optics Express*, 2022, 30(17): 30718-30726.
- [113] Kakkava E, Borhani N, Rahmani B, et al. Deep learning-based image classification through a multimode fiber in the presence of wavelength drift[J]. *Applied Sciences*, 2020, 10(11): 3816.
- [114] Deng Q L, Wen Z, Dong Z Y, et al. Spatially variant deblur and image enhancement in a single multimode fiber imaged by deep learning[J]. *Optics Letters*, 2022, 47(19): 5040-5043.
- [115] LeCun Y, Bottou L, Bengio Y, et al. Gradient-based learning applied to document recognition[J]. *Proceedings of the IEEE*, 1998, 86(11): 2278-2324.
- [116] Xiao H, Rasul K, Vollgraf R. Fashion-MNIST: a novel image dataset for benchmarking machine learning algorithms[EB/OL]. (2017-08-25) [2024-05-06]. <http://arxiv.org/abs/1708.07747v2>.
- [117] Deng J, Dong W, Socher R, et al. ImageNet: a large-scale hierarchical image database[C]//2009 IEEE Conference on Computer Vision and Pattern Recognition, June 20-25, 2009, Miami, FL, USA. New York: IEEE Press, 2009: 248-255.
- [118] Zuo C, Qian J M, Feng S J, et al. Deep learning in optical metrology: a review[J]. *Light: Science & Applications*, 2022, 11(1): 39.